

CUAI 하계 컨퍼런스 중간발표

| 2026-07-28

| NLP | 노지우

Rehearse, Then Recall — Cognitive Memory Strategies for Long-Context LLM Pipelines



#1 연구동기

- 장문 컨텍스트를 다루는 LLM 활용이 늘고 있음
 - 법률 문서 검토, 회의록·대화 이력 관리, 장문 문서 QA, 개인 비서형 에이전트 등은 모두 수만 토큰 이상의 정보를 오래 유지해야 하는 과제
- 하지만 **컨텍스트가 길어질수록 모델이 중간 정보를 놓치거나 사실과 다른 내용을 생성하는 현상이 반복적으로 보고됨** ("lost-in-the-middle" 등 선행연구에서 실증된 문제)
 - 단일 세션에서 컨텍스트 윈도우가 아무리 커져도, 그 안의 정보를 실제로 "기억"해서 정확히 꺼내 쓰는 데에 한계
- 반면 **인간은 훨씬 적은 용량으로도 긴 정보를 오래 유지하는 전략을 갖고 있음**
 - 인지심리학의 되뇌기(rehearsal), 검사효과(testing effect) 같은 기억 강화 전략이 대표적

사람이 정보를 오래 기억하기 위해 쓰는 이 전략들을
LLM의 장문 처리 파이프라인에 이식하면 정보 유지력이 실제로 향상되는가?

#2

선행연구

논문	RQ	Contribution	Limitation
ReadAgent (ICML 2024)	LLM이 상호작용적으로 읽기를 관리하면 원문 전체 입력보다 나은가?	페이지네이션·gisting·재조희 3단계 프롬프팅으로 원문 전체 입력을 능가	검사효과(능동 인출연습) 조건 없음, 균일칭킹 대비 이득 근소(86.83% vs 85.71%)
RECOMP (ICLR 2024)	압축된 컨텍스트가 다운스트림 QA에 실제로 도움이 되는가?	표면 유사도(ROUGE)가 아니라 "다운스트림 정답률"을 압축 품질의 훈련 신호로 제안	다중 근거 종합 시 추상 압축 취약, 충실성 하락
Multi-Step Pipeline (2024)	추출→추상 순차 파이프라인이 encoder-decoder 계열에서도 항상 이득인가?	순차 조합의 실제 효과를 실증 검증	encoder-decoder(T5/BART) 계열에서 추출 단계 추가가 오히려 손해일 수 있음

논문	착안한 점	개선하려는 점
ReadAgent	gisting("축약") 개념, 고정 길이 대신 자연스러운 지점에서 경계를 정하는 페이지네이션 아이디어	• LLM이 직접 경계를 판단하던 것을 코사인 유사도 기반 자동 계산으로 대체 (비용·비결정성 해소, 성능은 유지)
RECOMP	"다운스트림 정답률이 실제로 오르는가"를 훈련 신호로 쓰는 원칙	• 질문생성(검사효과) 모델을 추가해 "압축 후 인출 연습까지" • A에 verbatim 강제 후처리(원문 문장 스냅) + novel n-gram 조작점검을 추가해 충실성 하락 문제에 대응
Multi-Step Pipeline	추출→추상 순차 구조(A→B 결합 조건의 원형), encoder-decoder(T5) 사용	• "추출 단계 추가가 손해일 수 있다"는 경고를 그대로 받아들이지 않고 6조건 실험(1 vs 2, Ablation A1)에서 직접 검증·재현 시도 • 다단계 반복 추출의 노이즈 문제를 반영해 유지형 되뇌기는 1회 적용

RQ 1

Does **context reconstructed via rehearsal (maintenance/ elaborative) improve factoid retention (EM/F1)** over raw full-context input?

RQ 2


Does **combining a testing-effect step (QG, C) with rehearsal yield additional gains**, and if so, which rehearsal strategy benefits more?

RQ 3

Does this effect hold **consistently across text genres and information position**, suggesting a general principle transferable from human cognition to LLMs — or is it a narrow, condition-specific effect?

#4

파이프라인 아키텍처



4단계 구조:

1. 청크 분할 (원문 위치 기록)
2. 청크 요약 (Gisting — 임베딩 기반 문장 추출 압축)
3. 되뇌기 개입 (유지형/정교화, 선택적으로 검사효과 결합)
4. 최종 QA (LLM 프롬프팅, 필요시 원문 재조회)

핵심 원칙:

- **query-agnostic** — 청킹·gisting·되뇌기 단계는 최종 질문을 모르는 상태에서 수행
 - 실생활에서 최종 task를 알지 못하는 경우와 유사

#5

실험조건

#	조건	전략	심리학적 근거
0	Closed-book	컨텍스트 없이 질문만	오염 진단용
1	Raw full-context	개입 없음, 원문 그대로	하한선
2	유지형 되뇌기 (A)	핵심 사실 반복 재구성	Maintenance rehearsal
3	정교화 되뇌기 (B)	이전 맥락과 연결해 재구성	Elaborative rehearsal
4	A + 검사효과	A 출력에 QG로 Q&A 추가	Maintenance + Testing
5	B + 검사효과	B 출력에 QG로 Q&A 추가	Elaborative + Testing

#6

모델 설계 및 학습 데이터셋

model	task	input → output	training data
A. 유지형 되뇌기	extract	청크 → 핵심 문장 중심	`cnn_dailymail` (추출요약 근사)
B. 정교화 되뇌기	elaborate	이전 누적요약+새 청크 → 갱신된 재진술	`EdinburghNLP/xsum` (생성요약 근사)
C. 검사효과 (QG)	question	A/B 출력 청크(+정답) → 질문	SQuAD 역방향

- 세 모델 모두 공통 백본(`t5-base`)에서 출발하는 독립 체크포인트 — 조건 간 비교의 내적 타당도 확보
- A는 "복사에 가깝게"(verbatim), B는 "청크 간 관계까지 통합"(elaborative)이 핵심 차이

#7 평가 설계 - 5개 장르

5개 장르 × 6조건:


- 서사(NarrativeQA) / 위키(SQuAD) / 신문(CNN/DailyMail·NewsQA) / 법률 조항(원문+자체 QA 생성) / 법률 판례 (lex_glue case_hold)

장르별 평가 방식

- 서사·위키·신문·법률조항 : 모델이 **자유 응답(open-ended)**을 생성 → 정규화 후 **EM/F1(또는 BLEU 등)**로 채점.
- 법률판례(CaseHOLD) : 5지선다 객관식 → 응답에서 옵션 번호(1~5)를 파싱해 **accuracy**로 채점

#8

구현 현황 (1) 청킹 - 완료




#8 구현 현황 (1) 청킹 - 완료

- 구조: 원문 → 소스 어댑터(plain text/HTML → Paragraph 리스트) → 하드 제약(문장 무결성, 대사 묶음 무결성, 장면 전환 하드 경계) → 임베딩 기반 유관성 청킹
- 알고리즘 (TextTiling, Hearst 1997 계열)
 - a. scene break 등 하드 경계로 원문을 먼저 세그먼트로 나눔
 - b. 각 세그먼트 안에서 granularity 단위(기본: 문단, 옵션: 문장)로 임베딩
 - i. **NIM llama-nemotron-embed-1b-v2, input_type="passage"**
 - c. 인접한 두 단위 사이의 코사인 유사도를 전부 계산해 "이음매 점수" 리스트 생성
 - d. min_words~max_words 범위 안에 들어오는 이음매 후보들 중 유사도가 가장 낮은 지점을 청크 경계로 선택
 - e. 대사(따옴표) 묶음에 걸친 이음매는 후보에서 제외 — 대사 도중에 끊기지 않도록 보호
 - f. 임베딩 API 실패 시 _paginate_by_word_count_only(단어수만 보는 옛 방식)로 자동 폴백

#8 구현 현황 (1) 청킹 - 완료

Why?


- 선행 연구(1) ReadAgent에서는 min_words, max_words 를 기준으로 여러 지점을 제시한 뒤 LLM에게 MCQ형태로 청크를 나눌 구간을 선택하도록 함
 - LIMITATION**: 균일 청킹 대비 정확도 이득이 근소함(86.83% vs 85.71%) + LLM 호출 비용·비결정성이 대가
 - SOLUTION**: LLM이 청킹 구간을 선택하도록 하는 것이 아니라 모델이 수행하도록 함



#8

구현 현황 (1) 청킹 - 완료






- **처리 방식:** 청크를 하나씩 **독립적으로** 처리(롤링 없음)
 - 청크 내부에서 중요한 문장을 추출해 원문 순서 그대로 재구성
- **학습:** 공통 백본(t5-base)을 영어 추출요약 라벨 (cnn_dailymail)로 지도학습
 - 라벨 자체가 이미 "원문에서 뽑은 문장 집합"이라 별도 teacher distillation 불필요
- **verbatim 강제 후처리:** 생성된 각 문장이 원문에 실제로 존재하는지 문자열로 검증 → 없으면 코사인 유사도가 가장 높은 실제 원문 문장으로 스냅(snap)
 - 모델 구조를 바꾸지 않고 디코딩 후처리만으로 "표면 반복"을 강제
- **조작 점검(manipulation check):** novel n-gram 비율(원문에 없는 표현 비율)
- 청크 위치 메타데이터(문단 인덱스, 원문 문자 위치) 압축 후에도 그대로 보존
→ 이후 lookup·위치별 분석에 필요

#9

다음 단계



#10 RISKS & LIMITATIONS

- 5개 장르 확장에 따른 리소스 부담
 - **장르별로 채점 방식이 달라(EM/F1 vs BLEU/METEOR/ROUGE-L vs accuracy) 결과 해석이 복잡**해질 수 있음
- 실제 코퍼스 기반 4개 장르는 오염 가능성이 열려 있음 - closed-book 베이스라인 활용
- 영어 전환 후 청크 크기 설정(min_words/max_words)의 토큰 환산 비율 재실측 필요
- lookup(원문 재조회) 메커니즘은 이번 스코프에서 제외

감사합니다.