

CUAI 하계 컨퍼런스 CV 3팀 중간발표

2026.07.28

유금현, 조해웅(발표자)

주제 : Adversarial Attack on Multi-Image VLM

사람 눈에 보이지 않는 노이즈로 AI 답변을 조작하는 공격을,
여러 이미지를 함께 이해하는 최신 VLM에 적용하여 그 취약성을 진단

— 용어 정리 —


Adversarial Attack : 사람 눈에는 원본과 구분되지 않는 미세한 노이즈를 이미지에 심어,
AI 모델이 공격자가 의도한 대로 잘못된 답을 내놓게 만드는 기법

VLM : 이미지와 텍스트를 함께 입력받아, 이미지의 내용을 언어로 이해하고 답변하는 AI 모델

Multi-Image VLM : 이미지 한 장이 아니라 여러 장을 한꺼번에 입력 받아,
그 관계까지 함께 이해하고 답변하는 Vision-Language 모델

주제 선정 배경

1. 기존의 Adversarial Attack 연구는 Single-image 세팅 중심으로 진행되어 왔으며 Multi-image 환경에 대한 연구는 아직 초기 단계
2. 최신 연구(LAMP, 2026)는 새로운 공격 알고리즘 제안이 주된 기여, '어떤 조건에서 얼마나 취약해지는가'의 체계적 진단은 상보적 연구 방향으로 남아있음
3. Clean 세팅에서 보고된 이미지 순서 편향(Tian et al., 2025)과 Adversarial Attack 상호작용 또한 미조사



Multi-image VLM의 조건별 Adversarial Attack 취약성 체계적 진단

선행 연구

LAMP: Learning Universal Adversarial Perturbations for Multi-Image Tasks via Pre-trained Models

Alvi Md Ishmam, Najibul Haque Sarker, Zaber Ibn Abdul Hakim, Chris Thomas

Department of Computer Science, Virginia Tech

alvi@vt.edu, najibulhaque@vt.edu, zaberhakim@vt.edu, christhomas@vt.edu

LAMP, Ishmam et al., 2026

Learning Universal Adversarial Perturbations for Multi-Image Tasks via Pre-trained Models

다중 이미지 VLM을 대상으로 성공한 범용 공격 기법으로, 이미지 조합이 달라져도 동일한 노이즈 패턴 하나로 공격 가능함을 입증

- 이 공격 기법을 그대로 가져와, 이미지 순서·개수·압축·모델을 바꿔가며 성공률 변화를 측정하는 **실험의 기준 공격**으로 활용

Identifying and Mitigating Position Bias of Multi-image Vision-Language Models

Xinyu Tian¹ Shu Zou¹ Zhaoyuan Yang² Jing Zhang¹

¹Australian National University ²GE Research

¹firstname.lastname@anu.edu.au, ²firstname.lastname@ge.com

Identifying and Mitigating Position Bias of Multi-image VLM, Tian et al., 2025

공격이 전혀 없는 상황에서도, VLM이 **이미지 순서에 따라 특정 위치를 더 신뢰한다**는 편향 발견

- 이 "원래 있던 편향"이 공격 상황에서도 그대로 이어지는지, 즉 편향된 위치일수록 공격에 더 잘 뚫리는지를 검증하는 **Position** 축 실험의 출발점으로 활용

연구 방향

최신 SOTA 공격 메소드들을 활용해 취약성의 4가지 축을 진단

1. Position 축 : 이미지 순서(처음 / 중간 / 마지막)에 따른 공격 성공률 변화 측정

2. Count 축 : 이미지 개수(2, 4, 6장)를 늘렸을 때 취약성이 어떻게 변하는지 조사

-----중간발표-----

3. Corruption 축 : JPEG 압축·Resize 같은 자연스러운 변형 하에서 공격이 유지되는지 검증

4. Model 축 : Qwen2.5-VL, InternVL3, LLaVA-OneVision 등 최신 VLM 비교

새로 정의하는 진단 지표 : Position Sensitivity Score, Count Robustness Score, Corruption Resilience Score(Model 비교는 별도 지표x)

변경 사항 I - 공격 기법 변경

PA-Attack: Guiding Gray-Box Attacks on LVLm Vision Encoders with Prototypes and Attention

LAMP → PA-Attack

- : LAMP의 코드 및 학습된 Perturbation 비공개
- : LAMP 논문 재현을 위해서 A100 GPU 48시간 필요
- : 코드도 공개되어 있고, VRAM 24GB에서도 실험 가능한 PA-Attack으로 공격기법 변경

Hefei Mei¹ Zirui Wang¹ Chang Xu² Jianyuan Guo¹ Minjing Dong^{1*}

¹City University of Hong Kong ²The University of Sydney
{hefeimei2-c, zrwang23-c}@my.cityu.edu.hk
c.xu@sydney.edu.au, {jianyguo, minjdong}@cityu.edu.hk

PA-Attack이란?

- : VLM에서 Vision-Encoder를 타겟으로 공격하는 방법
- : 이미지를 생성하는 여러 AI 모델들이 동일한 Vision-Encoder를 사용한다는 것에서 착안(CLIP 계열)
- : Gray-box 공격

Vision-Encoder이란?

- : VLM은 이미지를 숫자로 변환하는 Vision-Encoder, 숫자를 언어로 변환하는 Language-Model로 구성

변경 사항 II – 평가 지표 변경

평가 지표의 변경

- : 주제발표에서는 각 축에 대한 새로운 평가 지표 정의
- : 새로운 지표 정의하는 것보다 선행연구에서 활용한 공통 지표를 활용하는 것이 축에 따른 비교에 적합
- : Clean Accuracy, Conditional ASR 이 두 지표로 진단 진행

Clean Accuracy

- : 공격이 없는 상태에서 모델이 정답을 맞추는 비율 (Position축은 위치, Count축은 이미지 개수)
- : 해당 연구의 신뢰도에 대한 지표로 활용될 수 있음

Conditional ASR

- : Clean 상태에서 맞혔던 문제들 중에서 Attack 받았을 경우 답이 틀리는 비율
- : 공격의 효과율 파악하기 위한 지표
- : 다만 질문이 어떤 거인지에 따라 분석을 나누어서 진행 필요

연구 절차

데이터셋 및 PA-Attack Prototype 확보

로컬 환경에서 스모크 테스트 진행

평가 하네스 구축

각 축별 Clean vs Attack 비교 (Position 축, Count 축)

결과 분석 및 시각화

데이터 셋 및 모델 소개

Mantis-Eval 데이터셋

- : 문제와 보기, 정답으로 구성된 데이터셋
- : 총 217 문제로 구성
 - 이미지 2장 - 145문제
 - 이미지 3장 - 39문제
 - 이미지 4장 - 32문제
 - 이미지 5장 - 1문제
- 문제 오류 있는 15문제는 평가 제외

InternVL2 모델

- : OpenGVLab에서 공개한
오픈소스 멀티모달 LVLM 모델
- : PA-Attack 저장소에 InternVL2
전용 공격 코드 구현되어 있어
해당 모델 사용
- : 선행연구에서도 해당 모델 사용하여
최초 실험은 해당 모델로 결정




사진1 사진2 사진3 Is it snowing in all images?

- A Image 1 is but others not
- B Image 2 is but others not
- C Image 3 is but others not

CHECK D In all images the weather is snowing

평가 하네스 구축

순열 생성기

: 이미지를 섞고 위치 재배치 - 처음/중간/마지막으로 분류 (이미지 2개인 경우에는 처음/마지막)

채점 도구

: Clean Accuracy, Conditional ASR, Prediction Inconsistency, Position Gap, Spearman 상관계수까지 5개 지표 계산

모델 호출 인터페이스

: InternVL2 모델 기준으로 실험 후 다른 모델을 같은 방식으로 그대로 실험하기 위하여 설계

로컬에서 검증 후 Position / Count 축 실험에 해당 하네스 그대로 사용

PA-Attack 공격 원리

Step0. PA-Attack에서 특징 그룹 20개 정의 (PA-Attack Prototype)

Step1. 공격할 사진 선택 → 해당 실험에서는 모든 문제의 1번째 사진 공격

Step2. 공격 대상 사진과 가장 안 닮은 그룹을 목표로 공격

Step3. 공격된 사진을 원래의 문제에 끼워넣기

Step4. 각 축별로 실험 진행

Position 축 실험

각 문제 별로 3개 버전 생성

- : 버전 1은 원본 데이터 순서 그대로
- : 버전 2, 3는 이미지 순서 무작위 (이미지가 2개짜리인 문제는 버전2까지만 생성)
- : 버전 2, 3에 대해서는 정답도 업데이트
- : 각 버전마다 Clean 이미지와 Attack 이미지 모두 VQA 진행

Clean Position

- : 공격이 없는 상태에서 각 버전에 따른 정답 정확도 파악
- : Clean Accuracy 지표 활용하여 InternVL2 모델의 추론 정확도 파악

Attack Position

- : Position Prototype 20개 그룹 중 가장 먼 그룹을 목표로 총 300번에 걸쳐 노이즈 입력
- : 각 문제의 첫번째 이미지에 노이즈 심은 뒤, 버전별로 순서 변경
- : Clean에서 맞았던 문제들 중 답이 틀리게 바뀐 비율 집계 (Conditional ASR)

Count 측 실험

Mantis-Eval 데이터셋을 이미지 개수에 따라 분류

- : 이미지가 2장(145문제), 3장(39문제), 4장(32문제), 5장(1문제)인 문제들로 분류
- : 각 이미지 개수 별로 Clean Accuracy가 얼마인지 확인(각 이미지 개수별 전체 문제 기준)
- : Position측 이후 별도의 실험을 돌리는 것이 아닌 Position측 실험의 결과를 활용

결과 분석 방법

- : 공격이 없는 문제들 기준으로는 이미지 개수별 Clean Accuracy 산정
- : 공격이 있는 문제들 기준으로는 이미지 개수별 Conditional ASR 산정
- : 해당 결과를 통해 결론 도출

결과 분석 – Position 측

Clean 결과


- : Position Gap 8.3%p로 높지 않고 전반적으로 일관된 Clean Accuracy
- : Position-Free 문제의 Prediction Inconsistency는 21.8%로 선행연구와 유사 (선행연구에서는 25.24%)

위치	Clean Accuracy
first	0.583
middle	0.500
last	0.533

Attack 결과

- : 특정 위치에 따른 공격 취약성은 뚜렷한 차이 없음
- : Position-Free 문제(보기에 내용만 언급)와 Position-Referencing 문제(보기에 이미지 위치 언급) 두 그룹(각 133문제, 69문제)으로 나누어 분석
- : Clean Accuracy는 두 그룹 유사, Conditional ASR에서 약 2배 차이
- : 이는 곧 위치까지 추론하는 문제가 공격에 취약함을 의미

위치(공격받은 이미지 기준)	Conditional ASR
first	0.241
middle	0.219
last	0.245



결과 분석 – Count 측



이미지 장수	Clean Accuracy
2장	0.578
3장	0.657
4장	0.309
5장	0.667 (표본 1개, 참고용)

Clean 결과

- : 이미지가 2장(145문제), 3장(39문제), 4장(32문제), 5장(1문제)인 문제들로 분류
- : Clean Accuracy 기준 이미지 4장인 문제 가장 낮음
- : 이는 이미지 4장 문제가 대부분 Image Reasoning 문제로, 문제 자체 난이도 높은 것으로 판단 (이미지의 설명에 대한 문제 – 27/32개)

Attack 결과

- : Conditional ASR 기준 이미지 개수에 따른 뚜렷한 변화 없음
- : Position-Referencing 문제에 한정하여도 이미지 개수에 따른 규칙성 발견하지 못함
- : 이미지 개수에 따라서는 공격 취약성이 달라지지 않는다



현재까지의 결론

Position 측 – 공격된 이미지가 특정 위치에 있을 때 유독 취약한가?

- : 공격된 이미지의 위치에 따른 취약성에 뚜렷한 변화 없음
- : 그러나 위치를 물어보는 문제일수록 공격에 취약하다는 결과 확인
- : 특정 자리보다 해당 문제가 위치 정보를 필요로 하는지 여부가 공격의 취약성을 더 잘 설명함

Count 측 – 이미지의 개수에 따라 공격의 취약성이 달라지는가?

- : 이미지 개수에 따른 공격 취약성에 대해 뚜렷한 결과 확인할 수 없음
- : Clean Accuracy 차이는 이미지 개수에 따른 차이가 아닌 문제 카테고리에 따른 차이로 확인됨
- : 여러 방식(이미지 개수 / 위치 참조 여부 / 카테고리 비교)으로 분석하여도 일관되게 이미지 개수와 공격 취약성 간의 뚜렷한 관계는 관찰되지 않음

향후 연구 계획

1. Count 측 재실험

: 동일한 문제 유형에 대하여 이미지 개수만 달리하여 다시 실험 진행

2. Corruption 측 실험 진행

: 기존에 사용한 평가 하네스 활용하여 JPEG Resize / 압축 시 공격 취약성 관찰

3. Model 측 확장

: Qwen3-VL, LLAVA One Vision 등 추가 검증

4. 타일링 오류 해결

: InternVL2 모델은 원래 타일링 방식으로 이미지를 쪼개서 인식

: 원래 자동으로 공간 마련 및 이미지 타일링 진행

: 이 과정에서 오류 발생하여 1장 전체를 인식 - 성능 저하

: 자동으로 쪼개는 것이 아닌 수동으로 공간 마련 및 이미지 타일링하여 진행