

CUAI 하계 컨퍼런스 MM 1팀:

A Chart-Consistent VLM Pipeline for Color-Vision-Deficient Users

2026.07.28

발표자 : 오규안

팀원 소개

오규안

신승현

배경: 색각 이상과 Chart Accessibility

전 세계 색각 이상자는 약 **3억 명**으로 추정되며, 선천성 색각 이상은 남성에서 최대 약 8%, 여성에서 약 0.5%까지 보고됨

차트는 색상을 이용해 범주, 추세, 강조를 표현하지만, 이러한 구분은 색각 이상자에게 모호하거나 인지되지 않을 수 있음

VLM은 원본 색상 정보를 기반으로 답변할 수 있지만, 사용자는 grayscale 또는 색각 이상 시뮬레이션 환경에서 차트를 봄


→ **모델의 답이 맞더라도, 사용자는 그 근거(색상 단서)를 확인할 수 없는 문제가 발생**

색상을 semantic information 자체가 아니라, grouping이나 emphasis를 위한 시각적 수단으로 보고 — 모델의 최종 추론은 사용자가 확인할 수 있는 비색상 단서에 근거해야 한다는 것이 본 연구의 핵심 문제의식

문제 사례: 색상 의존 질문

Slight increase in Japanese support for more active military role in the region

Japan should __ in the Asia-Pacific region



Q. "What is the difference between the highest and the lowest **green bar**?"

A (컬러 환경). 0.06

A (Grayscale 환경). ??? (초록 막대를 식별 불가)

Q'. "Look at the 'Play a more active military role'. What is the difference between the highest and the lowest bar?"

A (Grayscale 환경). 0.06 (컬러 환경과 동일한 정답 도출)

연구 질문 (Research Questions)

RQ1 현대 VLM은 ChartQA에서 실제로 색상 정보에 의존하는가?

완료

Grayscale 환경에서 Baseline 성능을 측정하고, 색상 제거가 실제로 정확도를 떨어뜨리는지 정량적으로 검증

RQ2 색상 기반 질문을 의미적으로 동일한 비색상 질문으로 변환할 수 있는가?

진행 중

Stage 1 (Query Refinement) · Stage 2 (Consistency-Guided Verification) 구현 완료 — Stage 3 (Iterative Refinement)는 TODO

실험 설정: Color vs Grayscale

데이터셋

ChartQA (Masry et al., 2022) — Human split / Augmented split

모델

Qwen2.5-VL-7B-Instruct, InternVL3-8B

조건


① 원본 컬러 이미지 ② Grayscale 변환 이미지 (색상 제거 시뮬레이션)

평가

정답과의 exact match (텍스트) / 상대오차 5% 이내 (수치)

※ 원본 컬러 이미지는 질문 refinement 및 검증 시에만 참조하고, 최종 답변은 항상 grayscale 이미지 기반으로 생성

Baseline 결과: 색상 제거 시 성능 하락



Qwen2.5-VL

79.60% → 70.96%

약 8.64%p 하락

InternVL3

75.28% → 66.72%

약 8.56%p 하락

* Augmented split은 거의 하락하지 않음 → 사람이 작성한 질문일수록 색상을 식별 단서로 더 많이 사용함을 시사

색상 의존 질문 사례 분석

색상 관련 키워드를 포함한 질문을 우선 수집하고, 실제로 색상이 차트 요소 식별에 사용되는 사례를 수작업으로 검토

251

개 색상 의존 질문

(2,500개 테스트셋 중 수작업으로 검증된 subset)

수집·검토 과정

- ① 색상 관련 키워드(red, blue, green bar 등)를 포함한 질문 exact-string 매칭으로 수집
- ② 색상 용어가 차트의 시각 속성이 아닌 고유명사(예: 'Red Sox')를 가리키는 경우 수작업으로 제외
- ③ 남은 질문을 색상 의존 subset으로 확정 → Stage 1-2 refinement의 핵심 평가 대상

이 subset에 대한 refinement 최종 성능 수치화 → TODO

Stage 1: Accessibility-Aware Query Refinement

색상 표현을 차트 내부의 의미적 표현(범례명, 카테고리명, 위치, 선 스타일 등)으로 변환하는 training-free 파이프라인

Color Chart + Original Question

"What is the greatest gap value between the orange and the green lines?"

Color Dependency Detection

색상이 주요 식별 단서로 쓰이는지 판단

Color Term Grounding

"green bar" → 범례 "U.S."

Rewritten Color-Agnostic Question

"...between the 'China' and 'U.S.' lines?"

Answer using Grayscale Chart

Grayscale 이미지 기반 1차 답변 생성

→ 1차 답변은 Stage 2에서 color-reference 답변과 비교되어 신뢰도가 검증됨

Stage 2: Consistency-Guided Verification


Grayscale 답변을 원본 컬러 이미지 기반 답변(color-reference)과 비교해 신뢰도를 검증

Color VLM Answering

원본 컬러 차트 + 원본 질문 → color-reference 답변

Gray VLM Answering

Grayscale 차트 + Stage 1 재작성 질문 → 1차 답변



※ color-reference 답변은 정답(ground truth)이 아니라, 재작성 질문의 신뢰도를 판단하기 위한 약한 검증 신호로만 사용

현재까지의 진행 상황

항목	상태
문제 정의 및 관련 연구 조사	완료
데이터셋 · 평가 환경 구축	완료
Color vs Grayscale Baseline 실험	완료
색상 의존 질문 탐지 및 subset 구축	완료
Stage 1: Query Refinement	구현 완료
Stage 2: Consistency-Guided Verification	구현 완료
Stage 3: Iterative Refinement	TODO
Consistency Resolution Branch	TODO
전체 모델 및 데이터셋 평가	TODO

TODO

Stage 1·2 만으로도 개선 가능성이 확인되지만, 잘못된 grounding이나 semantic drift가 발생할 수 있음

Stage 3: Iterative Refinement

Mismatch 사례에 한해 최대 5회까지 반복적으로 재수정 (targeted refinement)

Consistency Resolution Branch

반복 후에도 불일치 시, 재작성 이력을 후보로 두고 grayscale 증거로 최종 판단

Full Pipeline 평가

ChartQA · PlotQA 전체, 두 모델 (Qwen2.5-VL / InternVL3) 비교 및 ablation